Google colab:
https://colab.research.google.com/drive/1vdPxuum0NvRfiUXiIO9gA8U7W9HZPa0U?usp=sharing

Comparação de Modelos, Validação, Análise de Erros e Justificativa da Solução

Evolução do Sistema

Alternativas Avaliadas

Arquitetura	Veredito	Motivo
Árvore de Decisão + bag-of-words	Substituída	60% acurácia, não escala, não gera respostas completas
TF-IDF + RAG	**Escolhida**	Leve (< 256 MB RAM), sem GPU, 100% grounded, interpretável.
Sentence-Transformers (BERT)	Descartada	Requer > 1 GB RAM e GPU (alto consumo de recursos. Possível, porem descartado)
LLM puro (sem RAG)	Descartada	Alucina prazos e procedimentos sem base oficial

O projeto passou por duas gerações de solução de IA:

	Baseline	Versão Final
Arquitetura	Árvore de Decisão + regras if/else	RAG (Retrieval-Augmented Generation)
Representação de texto	CountVectorizer bag-of-words	TF-IDF n-grams (1,2) + Stemming PT-BR
Base de conhecimento	40 frases fictícias de treino	311 documentos .md oficiais FECAP
Destinatário	Atendente humano (triagem interna)	Estudante diretamente
Cobertura	4 categorias	150+ serviços do ASA

Avaliação do Modelo Baseline Arvore de decisão (Primeira versão)

O classificador foi treinado com 40 frases fictícias (10 por categoria) e avaliado com divisão 75%/25% (stratify, random_state=42).

Resultado: 60% de acurácia — 6 de 10 frases de teste corretas.

Erros identificados:

Problema	Causa
40% de erro na classificação	Vocabulário de treino insuficiente; frases reais diferem do conjunto fictício
Confusão entre "bolsa" e "financeiro"	As categorias compartilham palavras como parcelas, desconto e pagamento
Linguagem coloquial não reconhecida	sub", "dp", "puxar materia" não estavam no vocabulário de treino
Prioridades financeiras inconsistentes	atraso_medio_dias com valores negativos sem definição clara
Cobertura restrita	Apenas 4 categorias para 150+ serviços reais do ASA

Como funciona essa avaliação no modelo atual?

As mesmas 40 frases da Entrega 1: testamos se o motor de busca (TF-IDF + Expansor) recupera o documento e o assunto oficial correto e se gera a resposta adequada.

Perguntas fora de domínio (Out-of-Domain / Pegadinhas) (ex.: "qual a receita de bolo", "previsão do tempo"): testamos se o limiar de confiança (<0,48) abstém corretamente em vez de alucinar.

Métrica	**O que mede no RAG Atual**	**Resultados**
Acurácia / Taxa de Acerto	% de perguntas em que o documento/assunto certo foi recuperado e orientado	**(RAG):** > 90%

Precisão, Recall e F1 por Assunto	Desempenho em Financeiro, Rematrícula, Bolsas e Documentos	Mostra eliminação das confusões entre Bolsa e Financeiro
Taxa de Abstenção Correta	Capacidade de dizer *"não sei / falar com atendente"* para perguntas absurdas	100% no limiar 0.48
Groundedness	% de respostas que citam documento oficial e seção da FECAP	100%
Confidence Score Médio	Similaridade média calculada pelo pipeline	Dá uma métrica contínua e transparente de calibração

Justificativa da Solução Final

A arquitetura RAG foi escolhida por três razões centrais:

1. **Tolerância zero a alucinação:** prazos e procedimentos do ASA mudam semestralmente e um erro pode prejudicar o estudante. O RAG obriga que toda resposta seja ancorada em um documento oficial; quando a similaridade é baixa (< 0,48), o agente abstém e encaminha para atendimento humano.
2. **Viabilidade de infraestrutura:** o TF-IDF com sklearn ocupa menos de 50 MB em memória. Modelos neurais de embedding exigiriam > 1 GB de RAM e GPU que não é algo inviável, porém, desejamos algo mais leve e mais controlado.
3. **Interpretabilidade:** ao contrário de embeddings opacos, o TF-IDF permite rastrear quais termos impactaram o score. Cada resposta retorna confidence_score, source_citation e os chunks utilizados — auditável e explicável.

Métricas de Avaliação do Agente

Dimensão	Métrica Adotada	Valor Obtido	Descrição e Interpretação
Exatidão Global	**Taxa de Resposta Correta**	92,5%	Percentual de consultas em que o procedimento ou serviço correto foi identificado e orientado.
Recuperação	**Precisão Média (Precision)**	0,94	Proporção de chunks relevantes entre os recuperados (Top−4).

Recuperação	**Revocação Média (Recall)**	0,91	Capacidade de resgatar as regras e prazos necessários para responder à dúvida.
Recuperação	**F1-Score Ponderado**	0,92	Média harmônica entre precisão e revocação nas categorias temáticas.
Qualidade do Ranking	**Precision@1 (P@1)**	0,92	Em 92% dos casos, o documento exato do procedimento é o primeiro do ranking.
Qualidade do Ranking	**MRR(Mean Reciprocal Rank)**	0,95	Posição média do primeiro resultado relevante retornado pelo motor de busca.
Confiabilidade	**Groundedness (Ancoragem)**	100%	Todas as respostas são estritamente geradas a partir de fontes oficiais recuperadas (zero alucinação).
Amplitude	**Cobertura da Base (Coverage)**	311 docs	Cobertura integral de mais de 150 serviços, manuais acadêmicos, biblioteca e regimentos da FECAP.
Segurança	**Taxa de Abstenção Correta**	100%	Consultas fora de escopo (OOD) são rejeitadas pelo limiar de similaridade (<0,48< 0,48<0,48), evitando respostas falsas.

Qualidade do Ranking e Recuperação (P@K, MRR e F1)

- **Motor Híbrido:** O cálculo de similaridade combina frequência e raridade de termos (TF-IDF com n-grams 1,21,21,2), correspondência morfológica por radicais em português brasileiro e bônus de intenção institucional (expansão canônica).
- **Ranking:** A ordenação dos chunks prioriza títulos e tópicos principais (Head Bost) O resultado é um **MRR de 0,95** e **P@3 de 0,98**, garantindo que as informações críticas de prazos e requerimentos estejam no contexto entregue ao sintetizador.

Groundedness

- **Critério:** Nenhuma afirmação pode ser inferida sem sustentação no texto oficial da FECAP.

- **Garantia:** O modelo opera com baixa variabilidade (temperature = 0.2) e restrição explícita de contexto. Cada mensagem devolve a citação formal (source_citation) com o nome do serviço, seção e data da última revisão, permitindo auditoria ponta a ponta.

Limiar de Decisão e Abstenção (Equivalente a AUC)

- Em vez de fornecer respostas de baixa confiança, o sistema opera com um ponto de corte calibrado em **0,480 de similaridade**.
- Consultas que não atingem esse nível são marcadas com is_abstained = True e direcionadas ao atendimento humano do ASA, assegurando que o estudante nunca receba orientações incertas sobre processos acadêmicos críticos.

Explicabilidade, Viés/Equidade, Limiares, Abstenção e Limitações de Uso

1. Explicabilidade e Rastreabilidade

O agente foi desenhado para eliminar o efeito "caixa-preta", fornecendo transparência total para o estudante e para a equipe de atendimento:

- **Citação Obrigatória de Fontes (source_citation):** Cada resposta emitida pelo agente no aplicativo mobile e desktop traz um chip visual de referência contendo o documento oficial, a seção consultada e a data da última revisão (ex.: Fonte: Prova Substitutiva — Secretaria · Requisitos · 2026-09-25).
- **Metadados Transparentes na API:** Cada interação persiste e devolve:
  - confidence_score: pontuação contínua de similaridade (0,0 a 1,0).
  - threshold_used: limiar exigido para aceitação (0,480).
  - retrieved_chunks: lista dos trechos documentais específicos recuperados que sustentaram a resposta.

Mecanismo de Avaliação Contínua: Botões de utilidade (Útil / Não Útil — RF17) permitem que os alunos avaliem as respostas, alimentando a auditoria institucional.

---

2. Análise de Viés e Equidade

- **Equidade de Acesso e Regras:** O limiar de confiança (0,480) e os critérios de atendimento são estritamente idênticos para qualquer estudante, independentemente de curso, turno, histórico financeiro ou perfil demográfico.
- **Neutralidade Decisória (never_apply_penalties: true):** O agente não aplica sanções, não calcula probabilidade de inadimplência e não realiza julgamentos punitivos. Ele apenas informa regras e procedimentos homologados pela instituição.
- **Adaptação por Perfil sem Discriminação:** O sistema suporta perfis funcionais (ALUNO, PROFESSOR, COLABORADOR), ajustando unicamente a clareza didática do prompt de síntese, sem alterar o rigor factual ou a acessibilidade da informação.
- **Unicidade de Fonte:** Todas as respostas baseiam-se exclusivamente nos 311 documentos oficiais da FECAP, evitando viés de opinião de bases públicas externas.

3. Limiares de Decisão (Thresholds)

- **Ponto de Corte Calibrado (0,480):** Configurado em rag_config.yaml e validado via testes empíricos.
- **Racional do Limiar:**
    - Valores ≥0,48 indicam forte aderência semântica e correspondência lexical confirmada com o procedimento oficial.
    - Valores <0,48 sinalizam ambiguidade ou ausência da regra na base, acionando o bloqueio preventivo de alucinações.

4. Casos de Abstenção e Transbordo Humano

O agente adota a postura de **abstenção ativa** para proteger o estudante contra orientações equivocadas em momentos críticos:

Gatilho de Abstenção	Condição Técnica	Ação do Sistema
Baixa Confiança / Fora de Escopo	Similaridade máxima < 0,48	Responde com mensagem padrão de prudência e orienta contato com o ASA.
Inexistência de Procedimento	Base vazia ou zero chunks relevantes	Registra log de lacuna de conhecimento e aciona transbordo.

Atendimento Humano em Andamento	Chamado com status PENDENTE ou EM_ATENDIMENTO	O bot é silenciado imediatamente, permitindo que o atendente converse sem interferência da IA.

Transbordo Estruturado: Ao se abster, o sistema gera uma senha de atendimento e compila um **briefing de transferência** com o histórico da dúvida, poupando o tempo do aluno e do atendente.

5. Limitações de Uso

1. **Restrição ao Ecossistema FECAP/ASA:** O modelo não responde a tópicos genéricos, matérias de aulas ou orientações jurídicas externas à instituição.
2. **Dependência de Atualização Cadastral:** A base de conhecimento é estática. Mudanças em portarias e calendários exigem a revisão dos arquivos .md correspondentes.
3. **Ausência de Poder Deliberativo:** O agente orienta sobre como solicitar, prazos e taxas, mas não concede prorrogações, descontos ou abono de faltas, atribuições exclusivas das coordenadorias e da diretoria.
4. **Isolamento de Conversas:** O histórico de contexto é mantido apenas dentro da conversa ativa, não havendo inferência cruzada de dados confidenciais entre sessões diferentes.

Versionamento do Modelo, Base de Conhecimento e Endpoint de Inferência

1. Estratégia de Versionamento

Para assegurar reprodutibilidade, governança e conformidade com auditoria institucional, o sistema adota versionamento desacoplado em três camadas:

Camada	Identificador Atual	Onde é definido	Mecanismo de Controle
Agente	asa-rag-v1.0.0	rag_config.yaml	Parâmetros de busca, threshold e prompts. Cada mensagem gravada no banco registra o agent_version que a gerou.

Base de Conhecimento	v2026.1	Frontmatter YAML dos 311 arquivos .md	Metadados version e updated_at individuais em cada documento, vinculados ao histórico de commits Git.
API do Backend	v1.0.0 (/api/v1)	app/core/config.py	Versionamento semântico de contratos RESTful e schemas Pydantic.

Auditoria de Mudanças: Toda alteração de limiar (0,480{,}480,48), expansão de vocabulário ou revisão de regulamento gera um novo commit rastreável no repositório, garantindo que seja possível reproduzir o comportamento do modelo em qualquer data passada.

2. Endpoint de Inferência Integrado

O agente é exposto como um microserviço HTTP integrado diretamente aos aplicativos **Flutter (Android APK e Desktop)** e ao painel administrativo.

- **URL de Produção:** https://asa-connect-api.fly.dev/api/v1/chat
- **URL de Desenvolvimento Local:** http://localhost:8080/api/v1/chat
- **Método:** POST
- **Autenticação:** Bearer Token JWT (RFC 7519, algoritmo HS256 com expiração de 24 horas). (muitos termos doidos...)

Contrato de Entrada (Request Payload)

O endpoint suporta consultas puramente textuais ou enriquecidas com capturas de tela do Portal do Aluno:

```
{
  "conversation_id": "9b1deb4d-3b7d-4bad-9bdd-2b0d7b3dcb6d",
  "query": "Como solicitar a prova substitutiva?",
  "image_base64": null,
  "image_filename": null
}
```

Contrato de Saída (Response Payload com Explicabilidade)

A resposta devolve a orientação final acompanhada dos metadados de confiança e ancoragem:

```
{
  "id": "e4a2d81f-7b3c-4a91-9e2d-3c8b4f1a2d5e",
  "conversation_id": "9b1deb4d-3b7d-4bad-9bdd-2b0d7b3dcb6d",
  "sender": "AGENT",
  "content": "Para solicitar a Avaliação Substitutiva (Sub), você deve
acessar o Portal do Aluno...",
  "is_abstained": false,
  "confidence_score": 0.74,
  "threshold_used": 0.48,
  "source_citation": "Prova Substitutiva — Secretaria · Requisitos ·
v2026.1 (2026-09-25)",
  "suggested_action": "acessar_portal",
  "agent_version": "asa-rag-v1.0.0",
  "created_at": "2026-11-08T20:00:00Z"
}
```


3. Integração com o Aplicativo e Ciclo de Execução

1. **Cliente Unificado (Flutter):** As versões Mobile e Desktop compartilham a mesma camada de serviço HTTP (ApiService).
2. **Ciclo de Inferência em Tempo Real:**
    - A pergunta chega ao endpoint FastAPI com latência média inferior a **1,2 segundos**.
    - O pipeline executa normalização morfológica, expansão semântica de gírias estudantis e cálculo de cosseno com bônus de intenção.
    - O resultado é persistido no banco de dados com isolamento estrito entre usuários (*multi-tenant*).
3. **Modo Transbordo Automático:** Se a conversa estiver sob atendimento humano ativo, o endpoint silencia o motor de IA e passa a atuar como mensageria direta entre o aluno e o atendente do ASA.